PROIECT BUSINESS INTELLIGENCE

-Analiza datelor la nivel național pentru domeniul activități sportive, de recreere și distractive-

1. Descriere Problema de Business pentru care s-a realizat proiectul

Am realizat acest proiect dorind să surprindem principalele date economice și administrative din domeniul sportiv în ceea ce privește țara noastră. Conform caen.ro, acestui sector îi revine codul 93, iar în ceea ce privește analiza datelor, am pus accentul pe venituri, cheltuieli, pierderi, datorii, profit și am interpretat pe cele 41 de județe disponibile, la care adăugăm municipiul București, cum se repartizează până în momentul de față. Din lipsa unui număr relevant de date, ne-am concentrat atenția asupra întregii țări și nu doar la nivel de județ.

2. Pregătirea datelor

Prima dată am accesat site-ul data.gov.ro de unde am filtrat datele pe Ministerul Finanțelor, mai apoi alegând 4 ani consecutivi de referință pentru situațiile financiare pentru care am descărcat ulterior fișierele denumite WEB_BL_BS_SL_AN202x.txt și WEB_BL_BS_SL_AN202x.csv.

Filtrarea am continuat-o cu date de pe ONRC descărcând pentru anii de interes, fișierul cu date pentru firme neradiate cu sediu. De menționat aici , anul 2020 a avut 5 astfel de fișiere și le-am selectat pe toate.

Mai departe, am integrat toate aceste descărcări de care aveam nevoie în Tableau Prep pentru a începe curățarea propriu-zisă. Astfel, am adăugat în flow fișierele .csv și .txt descărcate anterior pentru situațiile financiare și am făcut pentru fiecare câte un Clean Step (Imagine 1). După ce am observat că fișierele .csv aveau ordinea inversă a coloanelor și rândurilor, am folosit un Pivot pentru a ajunge la structura de care aveam noi nevoie (Imagine 2). După acești pași am realizat un Union pentru a unifica cele 2 rezultate. Am repetat acești pași pentru cei 4 ani și am adăugat un Clean Step după fiecare Union pentru a reîmprospăta datele (Imagine 3). Am făcut un alt Union care leagă rezultatele obținute după toți cei 4 ani, iar Clean 17 are rolul de a revizui

datele duplicate, a filtra null values, a integra clasa CAEN și a elimina field urile care nu ne sunt necesare (Imagine 4) . În final, am mai adăugat un Clean Step pentru a păstra numai codurile CAEN pentru domeniul nostru și am eliminate clasa (Imagine 5).

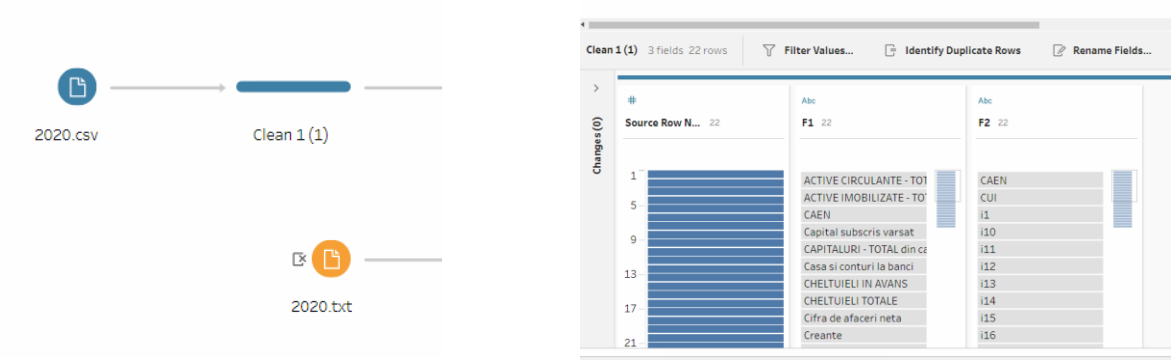

Imagine 1

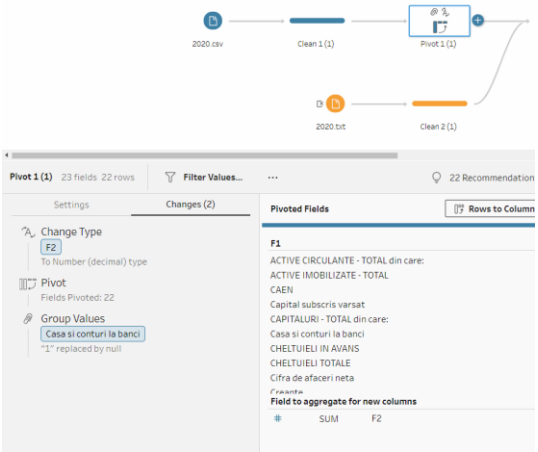

Imagine 2

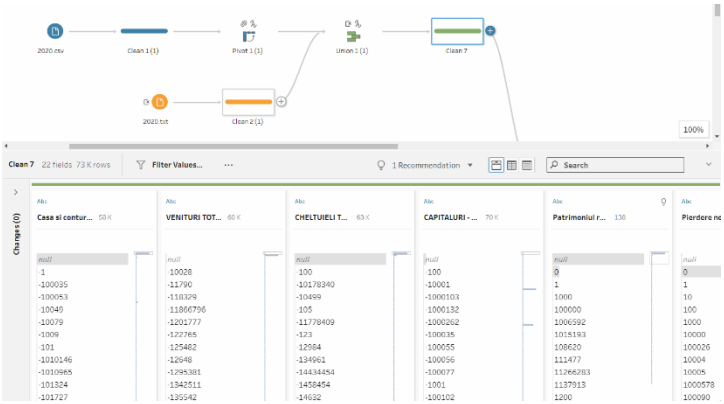

Imagine 3

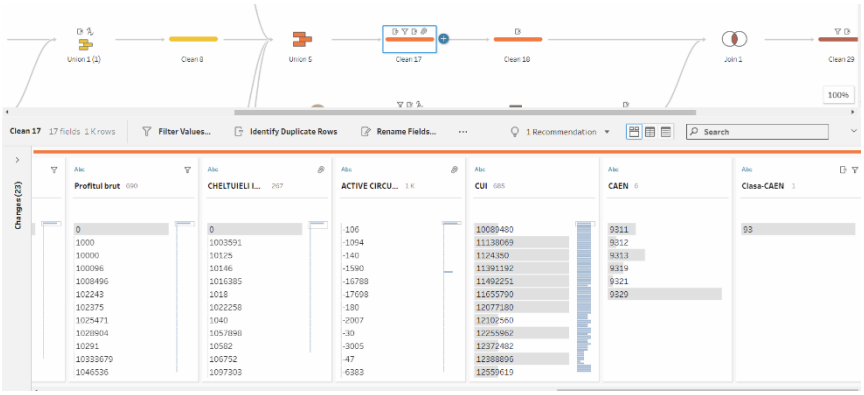

Imagine 4

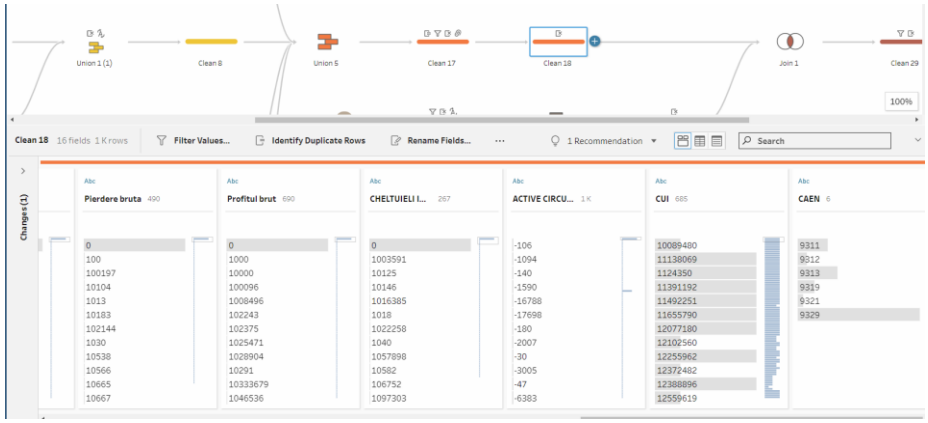

Imagine 5

În ceea ce privește datele financiare disponibile pe ONRC, descărcarea a decurs cu ușurință pentru firmele neradiate cu sediu pentru anii 2021-2023, provocarea a fost anul 2020, unde erau disponibile 5 astfel de fișiere și unde a fost necesar să le integrăm pe toate. Așadar, pentru anii 2021-2023 am procedat la fel, am adăugat ca prim pas un Clean Step de unde am filtrat valorile nule, am selectat numai câmpurile relevante și am schimbat tipul de dată pentru variabila CUI din NUMBER în STRING (Imagine 1). Pentru 2020, am luat fiecare fișier menționat anterior la care am aplicat Clean Step, cu aceiași pași ca la ceilalți ani, cu specificarea că celor 5 fișiere 2020 le-am făcut un Union separat înainte de a le lega de anii următori (Imagine 2). Pentru a avea seturi de date aerisite cu care să continuăm proiectul, Clean Step-urile de la toți anii, i-am fructificat în Union 13 care va prelua datele din toți acești ani filtrate fără valori nule, fără anumite câmpuri pe care nu le foloseam și păstrând tipul CUI String (Imagine 3). Fiind necesar încă un Clean Step pe acest flow pentru a elimina Table Names incluse automat de Union, îl facem și pe acesta, iar mai apoi realizăm un Join între Clean 18 și ultimul Clean Step de la firmele neradiate cu sediu pentru pentru a combina două tabele de date bazate pe o coloană comună, anume CUI (Imagine 4). Mai apoi, am făcut un Clean Step care să elimine coloana CUI ce a fost duplicată și pentru a elimina valorile nule rămase , iar ultimul Clean Step va reda forma finală a datelor pe care le-am curățat (Imagine 5).

La final, am general un Output.csv pe care să îl folosim mai departe la partea de proiect din Tableau Desktop (Imagine 6).

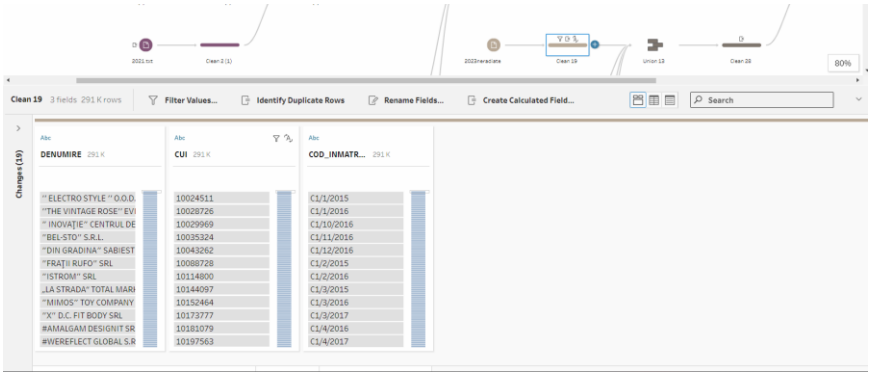

Imagine 1

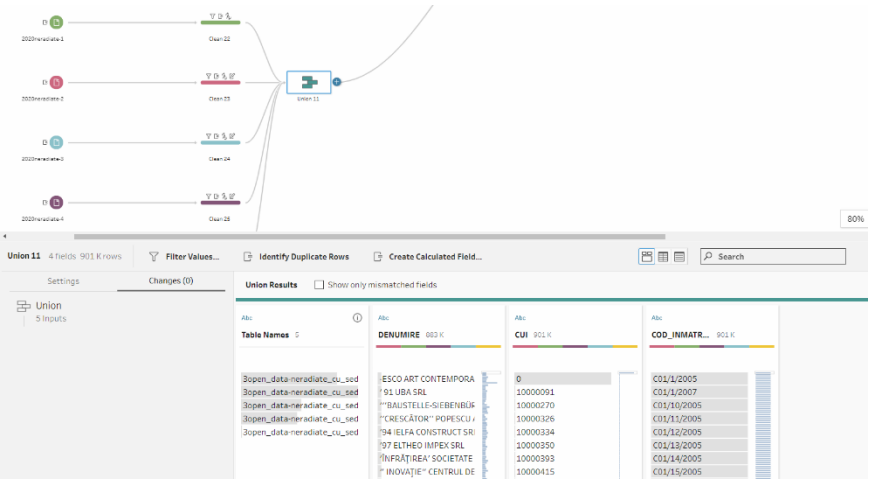

Imagine 2

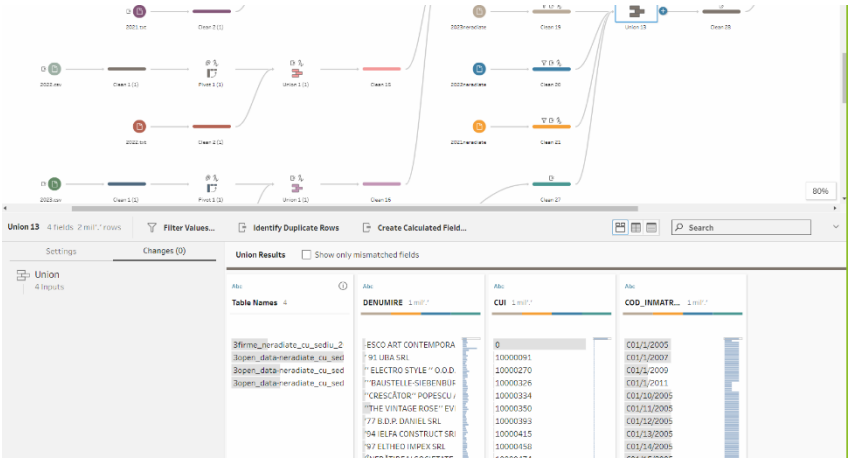

Imagine 3

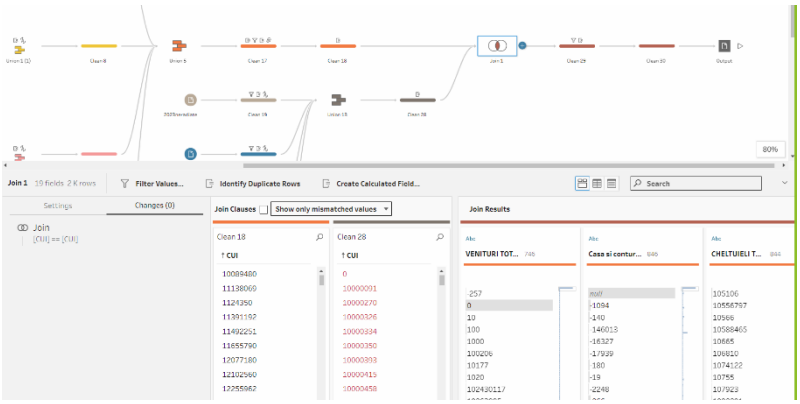

Imagine 4

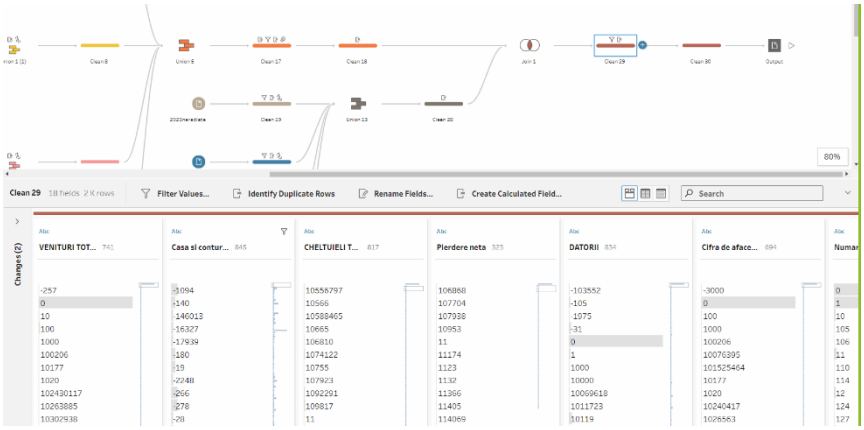

Imagine 5

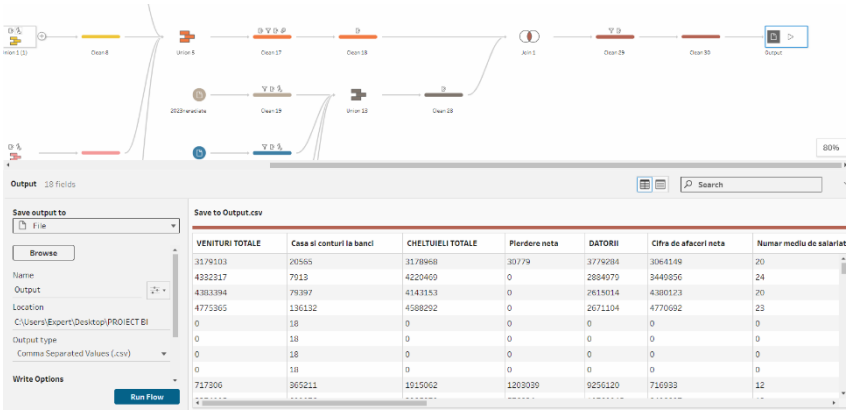

Imagine 6

3. Data Visualization & Analysis

Prima dată am observat că am avea nevoie de încă 3 tables anume: AN_INMATRICULARE, Județ și Nume Județ. Le-am realizat prin Calculated Field, pornind de la tabelul inițial COD_INMATRICULARE pe care am făcut diverse formule pentru a rezulta ce ne dorim. Pentru Județ am folosit această formulă: LEFT([COD_INMATRICULARE], 3) care extrage din COD_INMATRICULARE primele 3 litere (Imagine 1). Apoi, am făcut alt

Calculated Field bazat tot pe COD_INMATRICULARE denumit Nume Județ (Imagine 2) pentru a obține conform codului, numele județului reprezentativ, acesta este formula utilizată: IF LEFT([COD_INMATRICULARE], 3) = "J01" OR LEFT([COD_INMATRICULARE], 3) = "J1/" THEN "Alba"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J02" OR LEFT([COD_INMATRICULARE], 3) = "J2/" THEN "Arad"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J03" OR LEFT([COD_INMATRICULARE], 3) = "J3/" THEN "Argeș"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J04" OR LEFT([COD_INMATRICULARE], 3) = "J4/" THEN "Bacău"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J05" OR LEFT([COD_INMATRICULARE], 3) = "J5/" THEN "Bihor"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J06" OR LEFT([COD_INMATRICULARE], 3) = "J6/" THEN "Bistrița-Năsăud"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J07" OR LEFT([COD_INMATRICULARE], 3) = "J7/" THEN "Botoșani"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J08" OR LEFT([COD_INMATRICULARE], 3) = "J8/" THEN "Brașov"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J09" OR LEFT([COD_INMATRICULARE], 3) = "J9/" THEN "Brăila"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J10" THEN "Buzău"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J11" THEN "Caraș-Severin"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J12" THEN "Călărași"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J13" THEN "Cluj"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J14" THEN "Constanța"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J15" THEN "Covasna"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J16" THEN "Dâmbovița"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J17" THEN "Dolj"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J18" THEN "Galați"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J19" THEN "Giurgiu"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J20" THEN "Gorj"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J21" THEN "Harghita"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J22" THEN "Hunedoara"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J23" THEN "Ialomița"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J24" THEN "Iași"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J25" THEN "Ilfov"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J26" THEN "Maramureș"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J27" THEN "Mehedinți"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J28" THEN "Mureș"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J29" THEN "Neamț"

```
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J30" THEN "Olt"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J31" THEN "Prahova"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J32" THEN "Satu Mare"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J33" THEN "Sălaj"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J34" THEN "Sibiu"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J35" THEN "Suceava"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J36" THEN "Teleorman"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J37" THEN "Timiș"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J38" THEN "Tulcea"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J39" THEN "Vaslui"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J40" THEN "Vâlcea"
ELSEIF LEFT([COD_INMATRICULARE], 3) = "J41" THEN "Vrancea"
ELSEIF LEFT([COD_INMATRICULARE], 1) = "J42" THEN "București"
ELSE "Necunoscut"
END
```

Ulterior am avut nevoie și de anul de înmatriculare așa că l-am extras tot din COD_INMATRICULARE astfel: INT(RIGHT([COD_INMATRICULARE], 4)). Această formulă a luat din fiecare cod de înmatriculare numai anul, ceea ce ne interesa pe noi (Imagine 3).

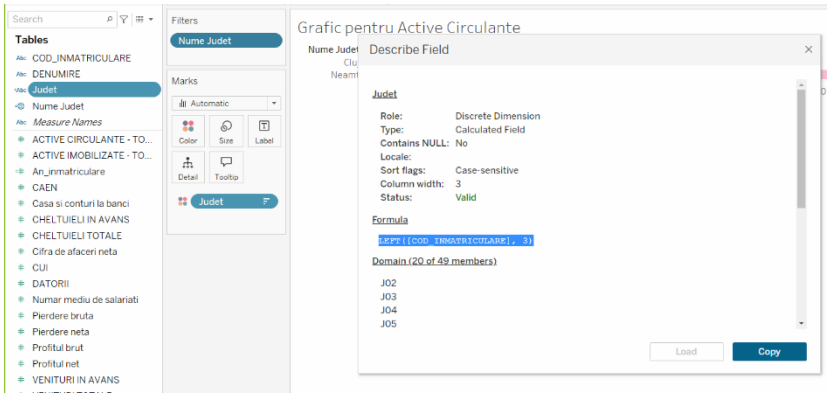

Imagine 1

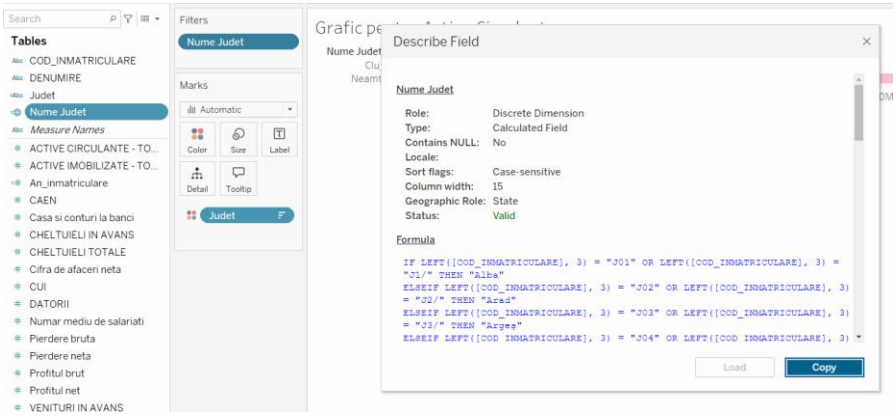

Imagine 2

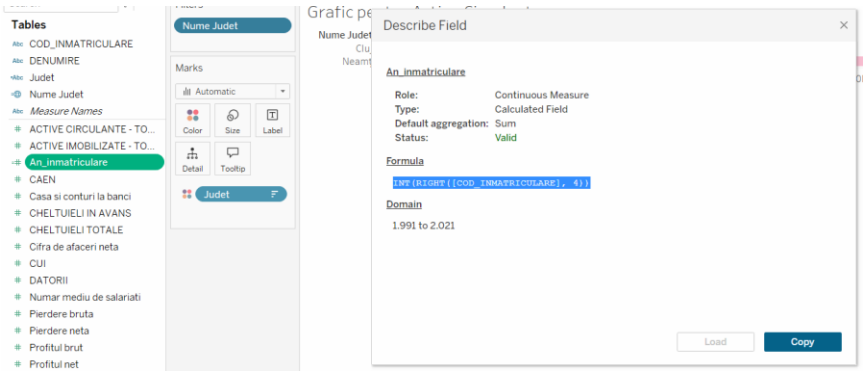

Imagine 3

Primul sheet din Tableau Desktop conține acest grafic prin care tratăm județele noastre natale și anume situația activelor circulante. Pentru a realiza graficul am folosit drept marcator Judet (trecut peste color) și pentru filtru Nume Judet (de unde am selectat doar județele noastre).

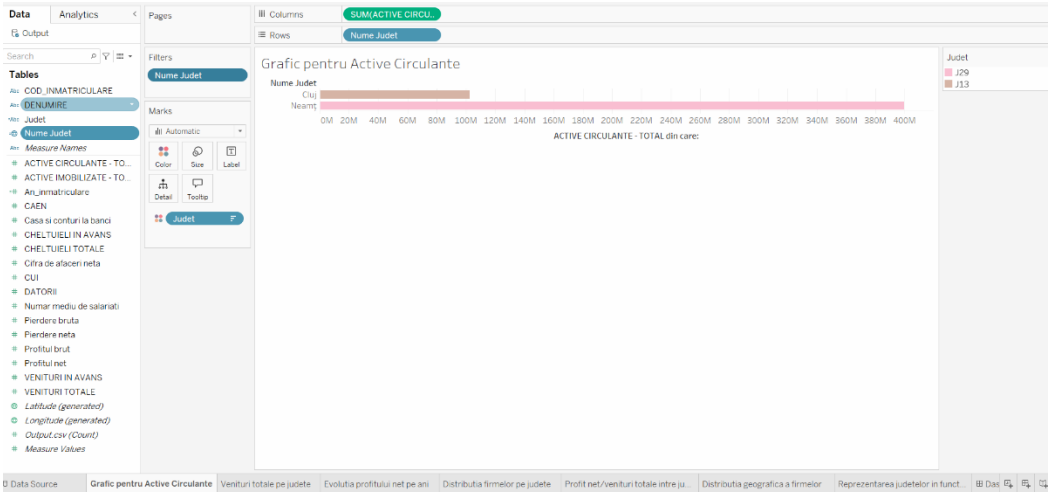

Am vrut să avem evidența veniturilor totale pe județe și pentru asta am păstrat același filtru, dar ca marcator am trecut peste color Nume Județ de data aceasta. Graficul arată astfel:

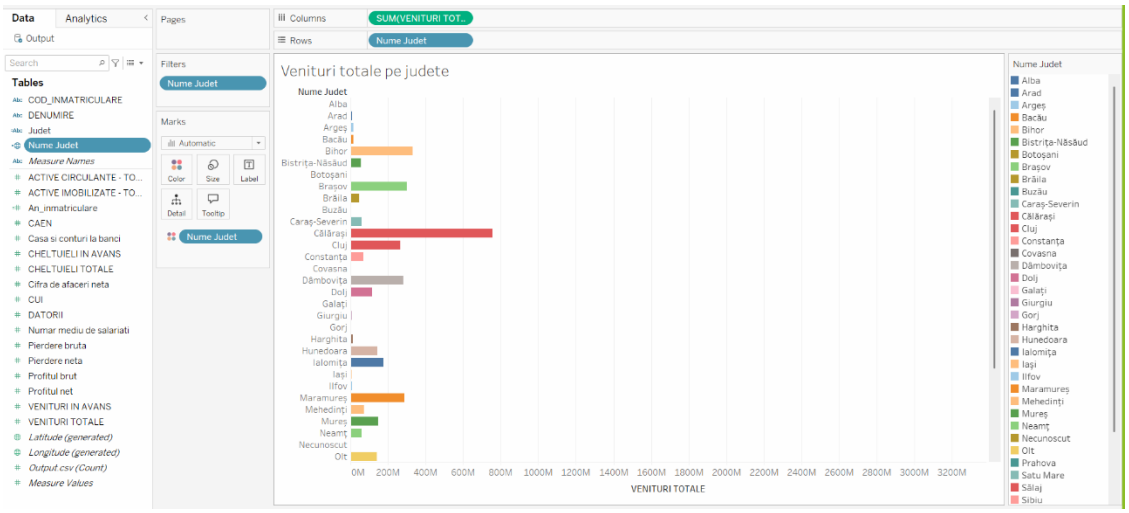

Ne-am gândit să analizăm evoluția profitului net pe ani, aici am avut nevoie de tabelul extras anterior (An_inmatriculare), în cadrul Filters am integrat Nume Judet, iar la Marks am notat pe color Nume Judet și pe Label Profitul net.

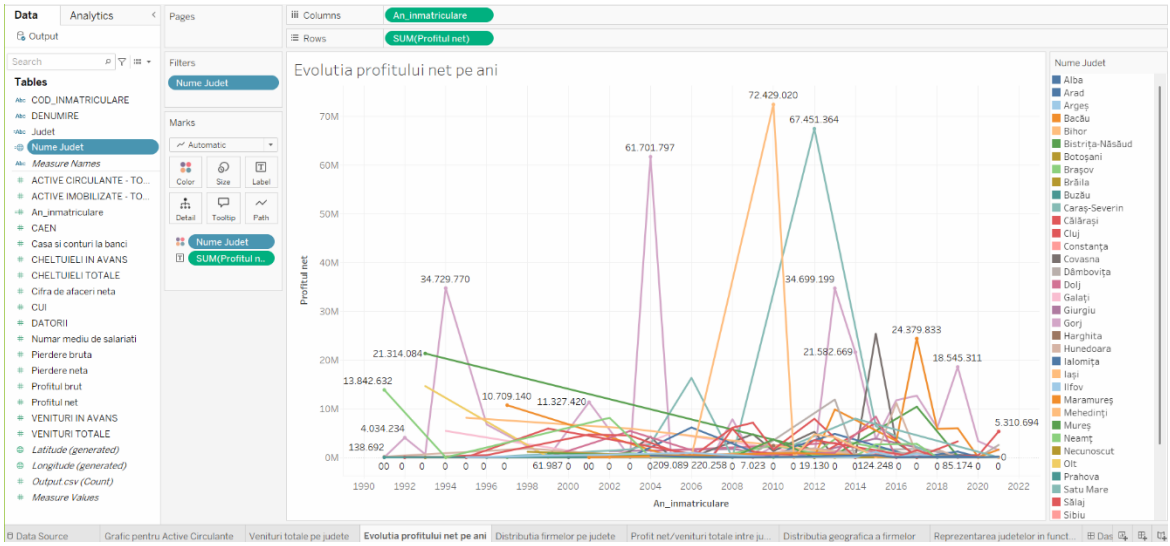

Pentru meniul Show me am dezvoltat 4 tipuri diverse de grafice:

Acesta este un Pie Chart ce ne arată distribuția firmelor din domeniul selectat pe județe. Drept filtru am selectat Nume Judet, iar la partea de marcatori avem Nume Judet pe color, Output.csv pe Angle și tot Nume Judet pe Label.

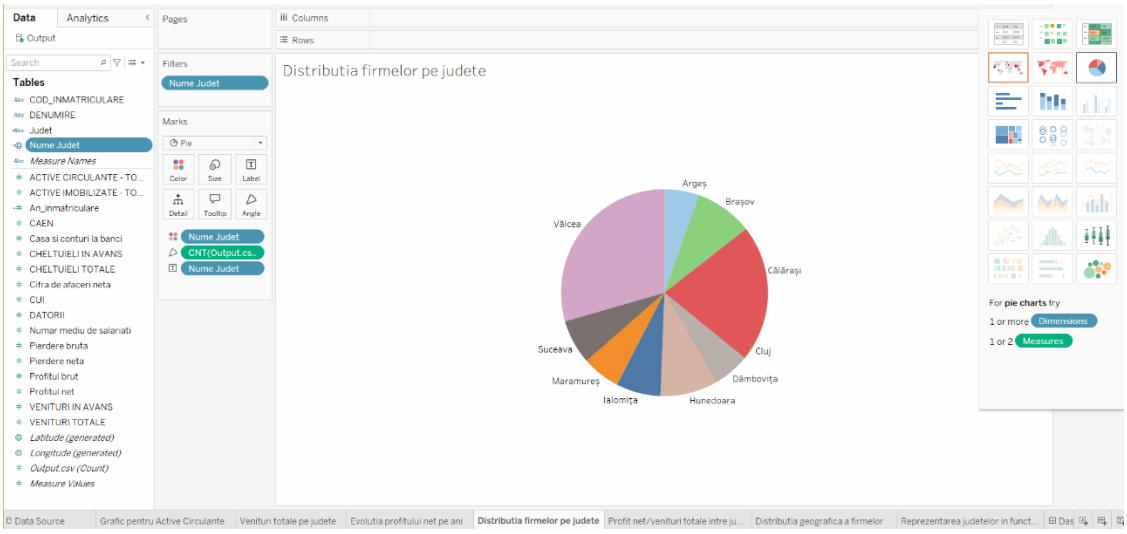

Pentru Show me, am evidențiat și treemaps unde am făcut o comparație la nivelul județelor între profitul net și veniturile totale pentru a observa aceste proporții. Putem vedea aici și filtrul present pe Nume Judet, dar și Marks unde apare pe Size și pe Color profitul net și Nume Judet pe Label.

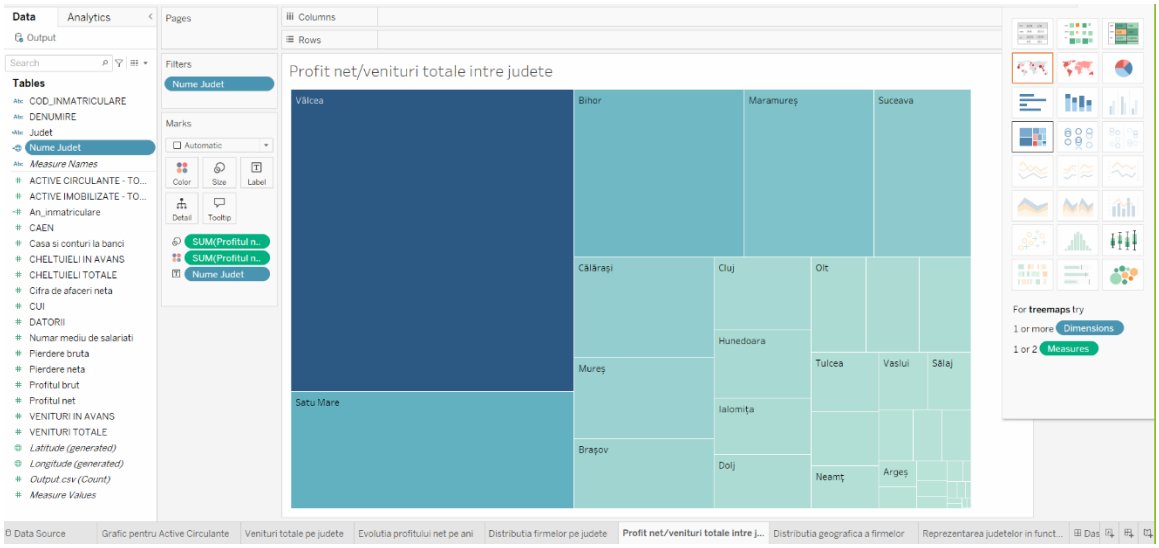

Am utilizat de asemenea și symbol maps, unde am redat concentrațiile firmelor pe județele țării. Pentru asta am selectat ca marcatori Nume Judet pe Detail și Output.csv pe Color.

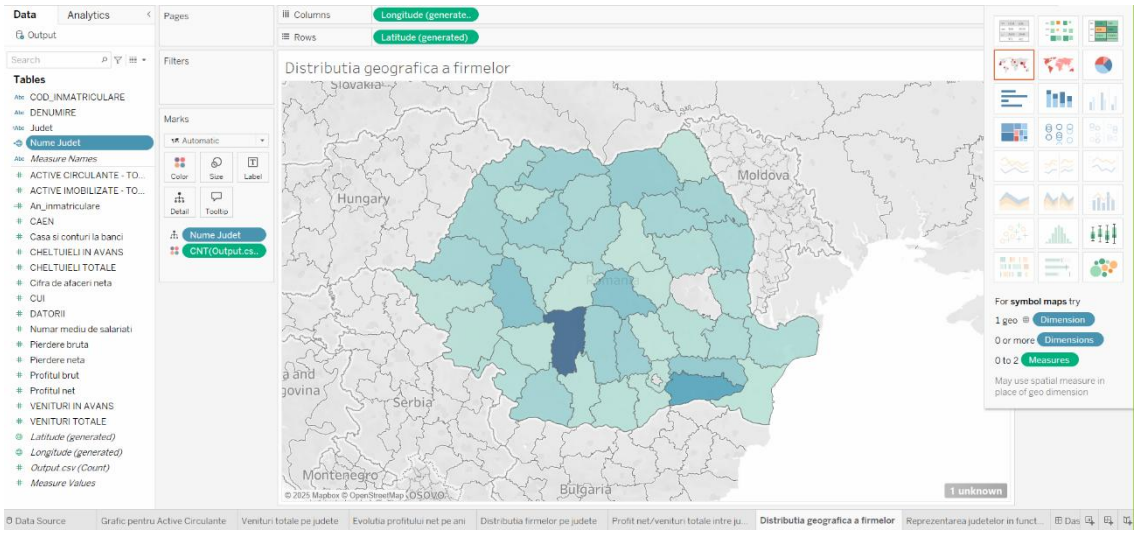

Ultimul element din Show me folosit este Packed Bubbles, iar această reprezentare am ales-o pentru a vizualiza județele în funcție de cheltuieli. Marcatorii utilizați sunt: Nume Judet pe color, Cheltuieli pe Size, Nume Judet pe Label.

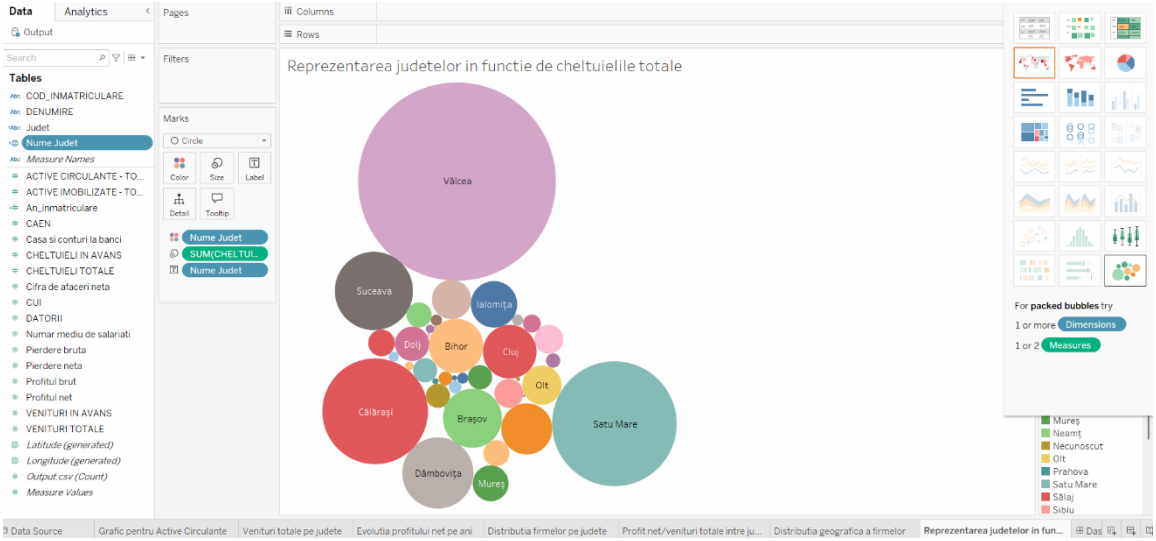

Următorul pas a fost Dashboard ul, unde am inclus toate worksheet urile de până acum.

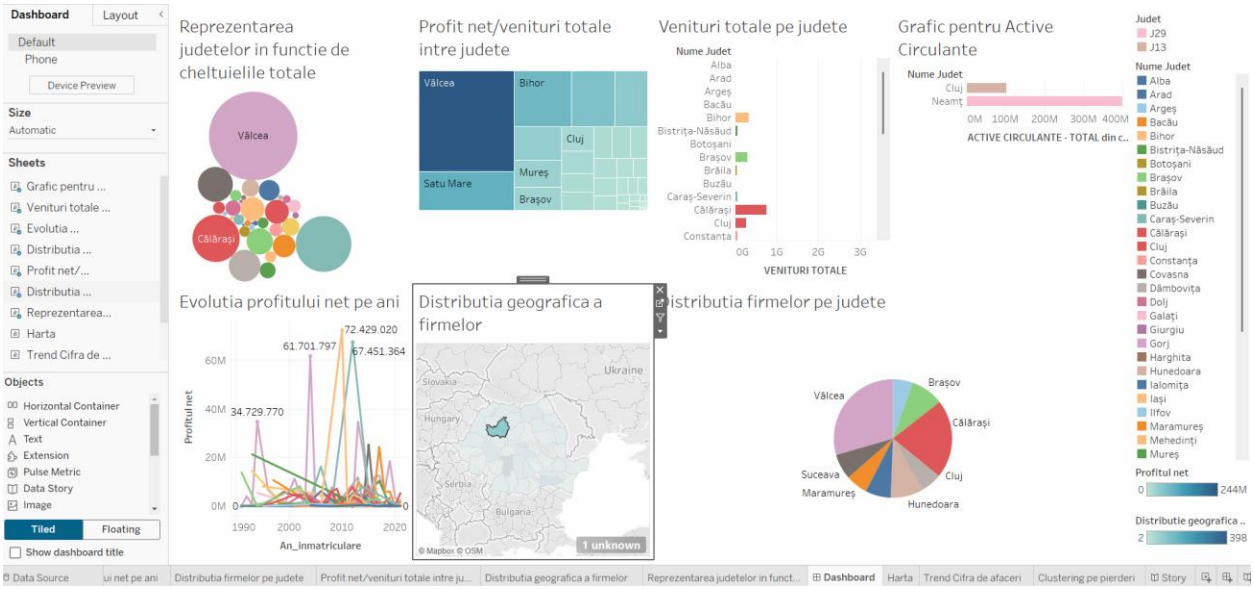

La Dashboard, după ce am făcut setările necesare (am pus Size-Automatic), am creat Action ul nostru care odată la selectarea unui județ de pe hartă va filtra toate worksheet urile pe care le conține pe datele aparținând județului respectiv.

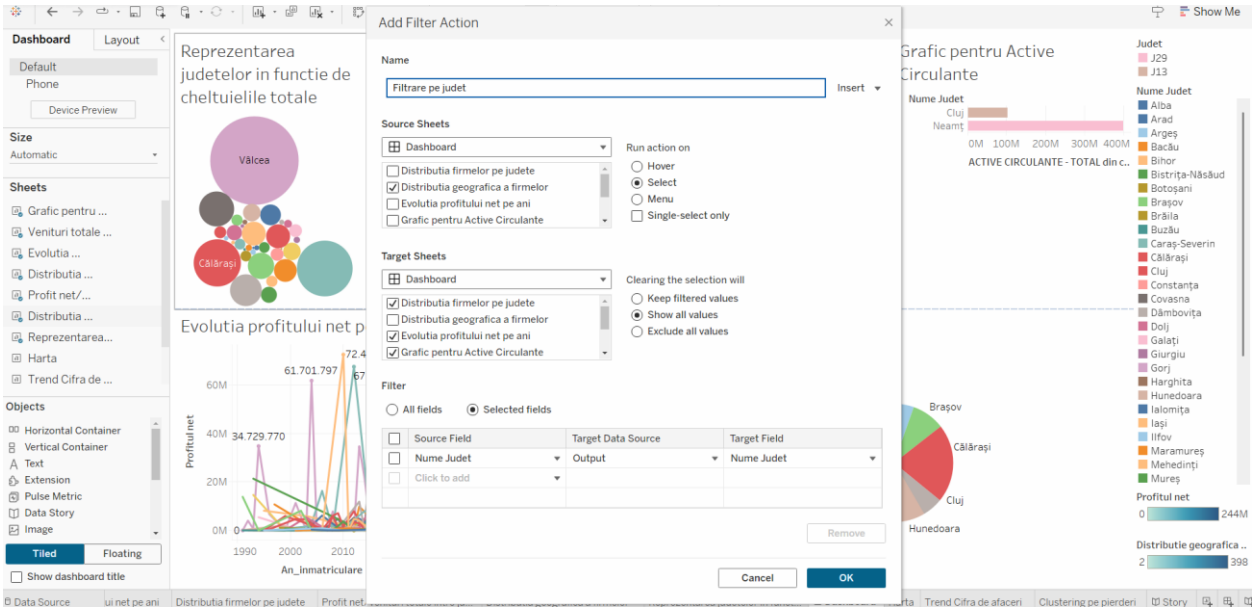

Exemplu: Județul Cluj

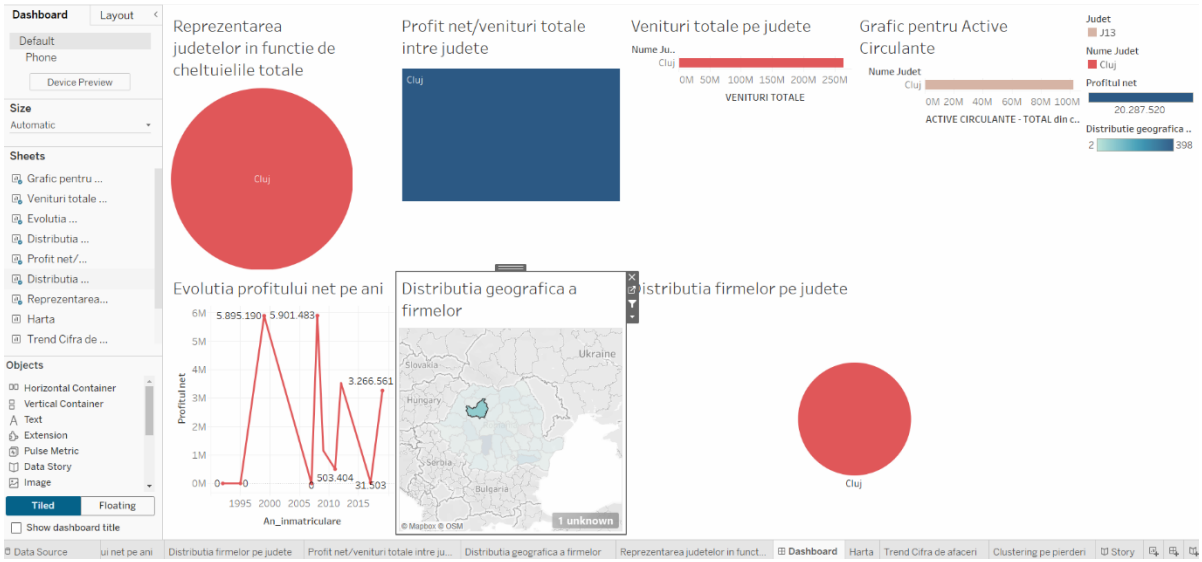

După aceasta am creat o hartă cu 3 straturi. Prima dată am selectat din meniul Show me (symbols map), apoi pentru primul strat am ales să scoatem în evidență numărul de firme și am

tras Output.csv în zona Size (astfel vedem câte firme sunt în fiecare județ). Al doilea strat, va nota cheltuielile totale pe fiecare județ, cercurile mai intense înseamnă cheltuieli mai mari (include CHELTUIELI TOTALE în zona Color). În final, al treilea strat redă numărul de salariați și datoriile (afișate la trecerea mouse ului peste județ); peste aceasta am inclus numărul de salariați în zona Detail și DATORII în zona Tooltip.

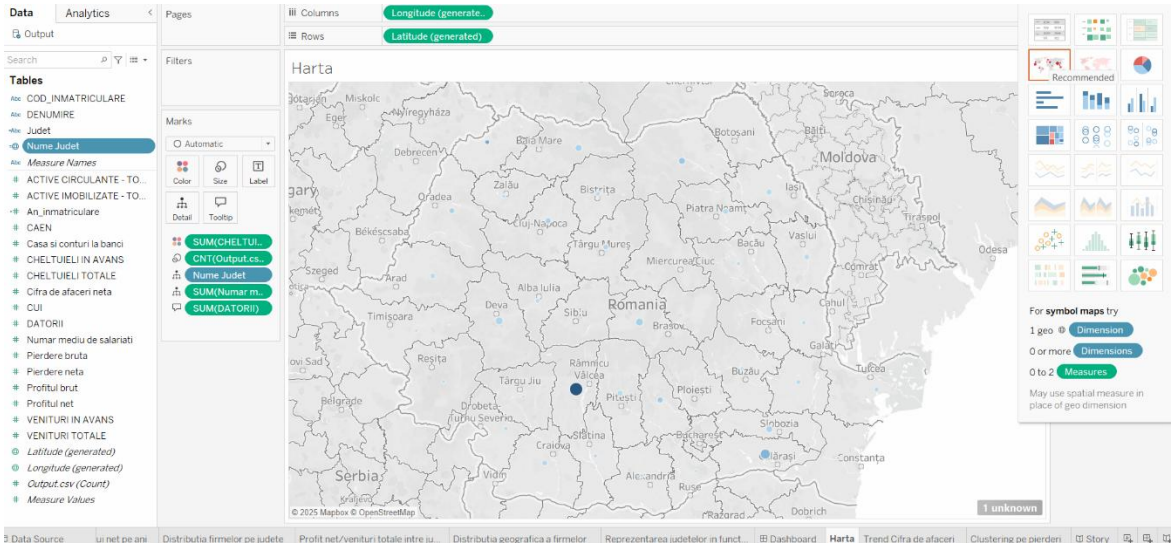

Analiza de trend în proiectul nostru constă în măsurarea evoluției Cifrei de afaceri în funcție de anul înmatriculării. Astfel, pe coloane o să avem An_inmatriculare, iar pe rânduri Cifra de afaceri. Trebuie să ne asigurăm că anul înmatriculării este de tip continuu pentru o analiză relevantă, iar apoi din tabul Analytics, vom pune pe graficul format din Model, Trend Line și selectăm varianta Linear.

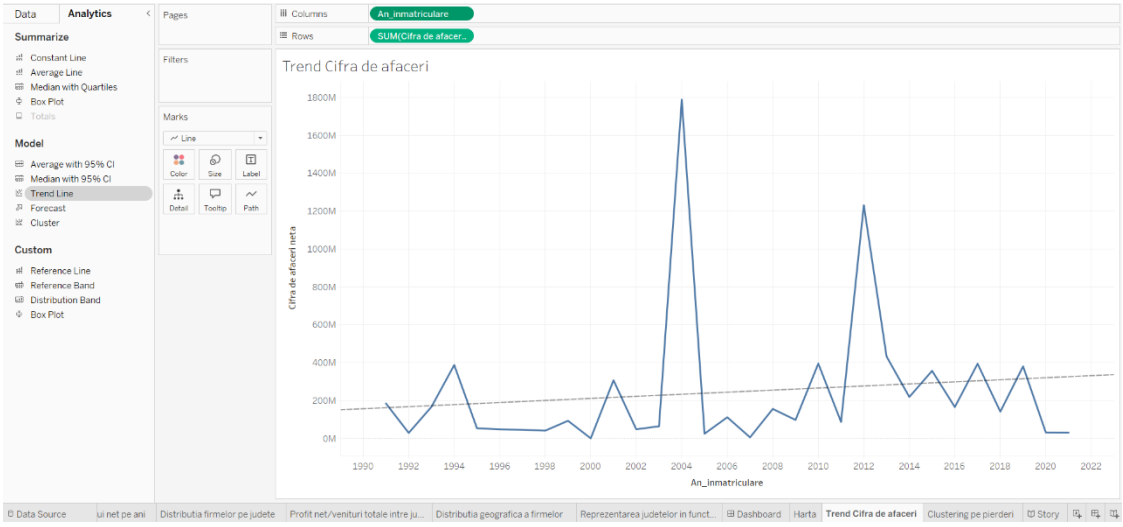

În ceea ce privește algoritmul de data mining, ne-am folosit de tehnica clustering care împarte județele în funcție de cât de mari sunt pierderile nete și brute. Fiecare bulină reprezintă un județ. Avem 3 clustere: primul înseamnă pierderi mici, medii; al doilea reprezintă județele cu cele mai mari pierderi brute și nete din întregul set, ultimul însumează valorile cu risc mediu, care se situează între clusterul 1 și clusterul 2. Ca formare, am ales drept marcatori Nume Judet pe Detail, iar opțiunea Cluster din tabul Analytics peste graphic și în Label pentru a diferenția grupurile. În Columns am integrat Nume Judet, iar în Rows Pierdere brută și netă.

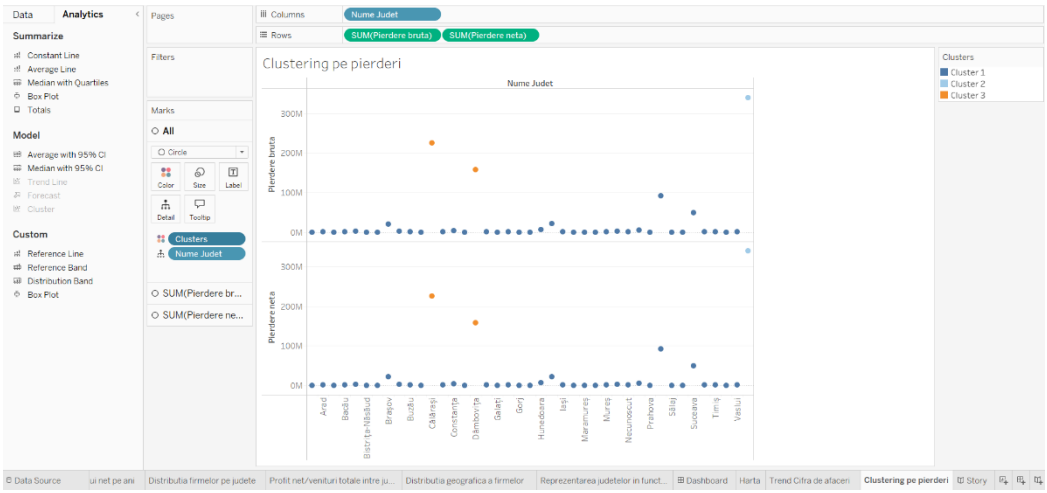

În final, am creat un story care cuprinde toate graficele ce au urmat după Dashboard, inclusiv Dashboard ul și am setat Size ul pe Automatic.

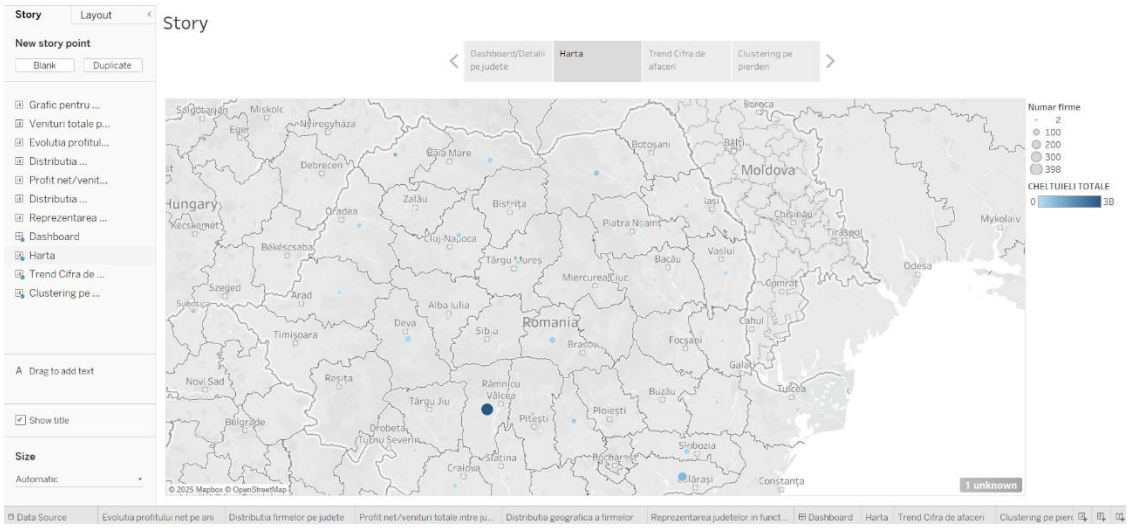

Echipa de lucru pentru proiect este formată din Ioniță Isabela și Kantor Beata, iar amândouă am lucrat concomitent la întreg proiectul. În ceea ce privește metodologia de lucru, noi am promovat abordarea Agile, un mod de lucru care nu cere planificarea de la început a fiecărui pas, ci permite testarea constantă a rezultatelor și corectarea erorilor.